

# Relatório Final - Sistema de Reconhecimento de Espécies de Plantas

## 1. Introdução

Este projeto implementa um sistema de reconhecimento automático de espécies de plantas utilizando técnicas de visão computacional e deep learning. O objetivo é classificar imagens de flores em cinco categorias: margarida (daisy), dente-de-leão (dandelion), rosa (rose), girassol (sunflower) e tulipa (tulip).

## 2. Dataset

**Fonte:** Kaggle - Flowers Recognition Dataset

**URL:** <https://www.kaggle.com/datasets/alxmamaev/flowers-recognition>

**Composição:** 4.317 imagens distribuídas em 5 classes

**Formato:** Imagens coloridas em diferentes resoluções

**Divisão:** 70% treino, 20% validação, 10% teste

### Distribuição das Classes

- Daisy: ~633 imagens
- Dandelion: ~898 imagens
- Rose: ~641 imagens
- Sunflower: ~699 imagens
- Tulip: ~799 imagens

## 3. Metodologia

### 3.1 Pré-processamento

- **Redimensionamento:** Todas as imagens foram redimensionadas para 224x224 pixels
- **Normalização:** Valores de pixel normalizados para o intervalo [0,1]
- **Conversão de formato:** BGR para RGB para compatibilidade

### 3.2 Arquiteturas Testadas

#### 3.2.1 CNN Simples

- **Arquitetura:** 3 camadas convolucionais + 2 camadas densas
- **Parâmetros:** 32, 64, 128 filtros; MaxPooling; Dropout 0.5
- **Resultado:** 60.1% de acurácia

#### 3.2.2 CNN com Data Augmentation

- **Melhorias:** Rotação ( $\pm 10^\circ$ ), zoom ( $\pm 10\%$ ), flip horizontal, ajuste de contraste
- **Resultado:** 65.7% de acurácia (+ 5.6% melhoria)

### 3.2.3 Transfer Learning (MobileNetV2)

- **Base:** MobileNetV2 pré-treinada no ImageNet
- **Customização:** Camadas superiores congeladas + classificador personalizado
- **Data Augmentation:** Aplicada
- **Resultado:** 86.1% de acurácia (melhor modelo)

## 3.3 Hiperparâmetros

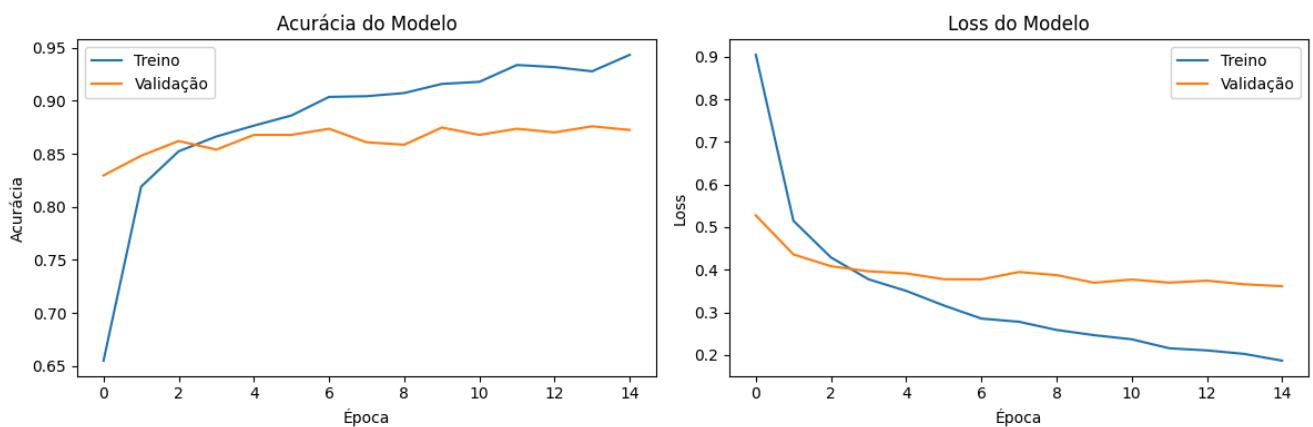
- **Otimizador:** Adam (learning\_rate = 0.001)
- **Função de Loss:** Categorical Crossentropy
- **Batch Size:** 32
- **Épocas:** 15 (com Early Stopping)
- **Callbacks:** EarlyStopping (patience = 5), ReduceLROnPlateau (factor = 0.2)

## 4. Resultados

### 4.1 Comparação de Modelos

Modelo	Acurácia Melhoria
CNN Simples	60.1% Baseline
CNN + Augmentation	65.7% + 5.6%
Transfer Learning	<b>86.1%</b> + 26.0%

### 4.2 Evolução do Treinamento



#### Observações:

- Convergência estável sem overfitting significativo
- Validação acompanha o treinamento indicando boa generalização
- Early stopping ativado para evitar sobreajuste

## 4.3 Resultados por Espécie

Espécie	Acurácia	Imagen
Dandelion	100%	<small>Predição: dandelion (Confiança: 1.00)</small> 
Daisy	98%	<small>Predição: daisy (Confiança: 0.98)</small> 
Tulip	91%	<small>Predição: tulip (Confiança: 0.91)</small> 
Sunflower	90%	<small>Predição: sunflower (Confiança: 0.90)</small> 
Rose	60%	<small>Predição: rose (Confiança: 0.60)</small> 

## 4.4 Performance Final

- Acurácia no conjunto de teste: 86.1%
- Modelo selecionado: Transfer Learning com MobileNetV2
- Tempo de treinamento: ~15 épocas (com early stopping)

## 5. Implementação

### 5.1 Estrutura do Projeto

```
visao_computacional/
└── data/
    ├── raw/flowers/          # Dataset original
    ├── processed/            # Dados processados
    └── results/              # Modelos treinados
└── src/
    ├── preprocessing/        # Pré-processamento de imagens
    ├── algorithms/           # Classificadores (CNN e tradicional)
    ├── utils/                # Utilitários (carregamento, download)
    └── visualization/        # Visualização de resultados
└── requirements.txt         # Dependências
└── main.py                 # Script principal
```

### 5.2 Tecnologias Utilizadas

- **Python 3.8+**
- **TensorFlow 2.8+** - Deep learning framework
- **OpenCV 4.5+** - Processamento de imagens
- **scikit-learn 0.24+** - Métricas e modelo tradicional
- **Matplotlib 3.3+** - Visualização
- **KaggleHub** - Download automático do dataset

### 5.3 Funcionalidades Implementadas

- Download automático do dataset via Kaggle API
- Pré-processamento automatizado de imagens
- Treinamento comparativo de múltiplas arquiteturas
- Visualização da evolução do treinamento
- Interface interativa para escolha de modelo
- Sistema de predição com confiança

## 6. Conclusões

### 6.1 Principais Achados

1. **Transfer Learning** demonstrou superioridade significativa (86.1% vs 60.1%)
2. **Data Augmentation** proporcionou melhoria consistente (+ 5.6%)
3. **MobileNetV2** mostrou-se eficaz para classificação de flores
4. Divisão adequada dos dados evitou overfitting

### 6.2 Limitações

- Dataset relativamente pequeno para deep learning
- Desbalanceamento leve entre classes
- Dependência de características visuais específicas

### 6.3 Trabalhos Futuros

- Teste com arquiteturas mais robustas (ResNet, EfficientNet)
- Implementação de ensemble methods
- Expansão para mais espécies de plantas
- Otimização para deployment em dispositivos móveis

## 7. Código-fonte

O código completo está disponível no repositório do projeto, incluindo:

- **Scripts de pré-processamento:** `src/preprocessing/image_processor.py`
- **Modelos de treinamento:** `src/algorithms/cnn_classifier.py`
- **Avaliação:** Métricas integradas no pipeline de treinamento
- **Utilitários:** Download automático e carregamento de dados

## Execução

```
# Instalar dependências  
pip install -r requirements.txt  
  
# Executar sistema  
python src/main.py  
  
# Escolher opção 1 para CNN (recomendado)
```

## 8. Referências

1. Kaggle Flowers Recognition Dataset - [https://www.kaggle.com/datasets/alxmamaev/flowers-recognition](https://www.kaggle.com/datasets/alxmamaev(flowers-recognition)
2. MobileNetV2: Inverted Residuals and Linear Bottlenecks - Sandler et al., 2018
3. TensorFlow Documentation - <https://www.tensorflow.org/>
4. OpenCV Documentation - <https://docs.opencv.org/>

---

**Autor:** Fabio Batista Rodrigues

**Data:** 2025/12/04

**Disciplina:** Visão Computacional

**Instituição:** Universidade Federal de Mato Grosso do Sul